

DATA LAKE

- └ Minimum 2 types de données différentes (struct + unstructured)
- └ Minimum une source de données externes (APIs, fichiers, etc.)
- └ ELT approach (Extract → Load → Transform)
- └ Schéma flexible (schema-on-read)
- └ Données stockées en format original/brut

Exemple dataset:

- └ Wikipedia + News articles + Images

DATA WAREHOUSE

✓ Requis:

- └ Données structurées UNIQUEMENT
- └ ETL approach (Extract → Transform → Load)
- └ Schéma fixe défini AVANT stockage (schema-on-write)
- └ Minimum 10 KPIs métier calculées
- └ SQL queries optimisées (indexes, agrégations)
- └ Dashboard de ressources
- └ Montrer la performance SQL (temps queries)

Exemple datasets:

- └ E-commerce (sales, products, customers)
- └ Financial data (stocks, transactions)
- └ Sports statistics (teams, players, games)

DATA LAKEHOUSE

- └ Minimum 2 types de données (struct + unstructured)
- └ 3 couches implémenter:
 - | └ BRONZE: données brutes, ELT
 - | └ SILVER: nettoyage + metadata
 - | └ GOLD: KPIs + schéma fixe

└ Monitoring: mesurer chaque couche (coût, latency, qualité)

Exemple datasets:

└ News + Stock prices + Sentiment analysis

└ NYC Taxi + Weather + Traffic

└ E-commerce + Customer reviews + Images
